传智杯 AI WEB 开发挑战赛

织识 Loom

个人知识库助手

AI 负责让你看清，不负责替你想清楚

作品类型：Web 应用（Next.js 全栈）

线上演示：http://8.163.104.134

代码仓库：https://github.com/Andre-lingfeng/loom

提交日期：2025 年 11 月

1. 问题

1.1 起点：一个自己的习惯

这个作品不是从「想做个 AI 应用」开始的。

> 在短视频软件里，我收藏了很多自己认为有用的视频。但这些视频进了收藏夹之后就再没打开过，有些甚至没完整看完。后来我开始留意到这种情况，会不定期打开「我的收藏」，但收效甚微。

这里的失败不在「找不到」，而在**收藏这个动作本身提供了「我已经获得了」的错觉**。收藏越方便，这种错觉越强。

复述一遍行为链：看到 → 觉得有用 → 收藏 → **获得心理上的完成感** → 不再打开。问题出在第四步——收藏替代了学习，而不是通往学习。

竞赛只是这个作品的引线。困扰在这之前就有了，作品是顺着它长出来的。

1.2 现象抽象

知识管理工具解决的是「存」，但存完之后的学习过程没人管。

三个可观察的失败模式：

失败模式	表现	现有工具的对策
存了不看	收藏夹里 300 条，一条没重读过	无（甚至用「一键剪藏」加速囤积）
看了不写	读完觉得懂了，合上就忘	无
写了不判断	素材之间互相矛盾，笔记却拼成一段自洽的结论	无

第三条最危险：模型会把两条冲突的材料缝合成一段流畅但错误的总结，而用户不会察觉。

1.3 主张

> **AI 负责让你看清，不负责替你想清楚。**

产品把「输出」变成流程的一部分，而不是可选动作：

- 存素材必须写一句「为什么存它」，否则进收件箱挂着
- 写作前先查缺口，指出哪些论点没有证据
- 素材之间矛盾时，模型标出来，但**必须由用户做出判断**才能收口

1.4 目标用户

自己写东西的人：学生、研究者、写作者、产品经理。共同点是「需要把读到的材料变成自己的判断」。

反过来，不用写东西、只是收集资料的人不需要这个工具——他们需要的是搜索，不是判断。

---

2. 设计取舍

> 这一节是全文最该体现"为什么"的地方。每条决策都应写成「候选方案 → 选择 → 理由 → 代价」。

2.1 不做账号体系

账号体系一开始是**计划要做的**，后来主动砍掉。两个原因：

1. **时间与安全。**短时间做出来的账号体系，安全性无法保证。而在"有一个能用的账号"和"用户数据是安全的"之间，后者重要得多。
2. **存储成本。**资金有限，服务器配置很低，没有余力搭数据库。

方案	选择	理由	代价
账号 + 云端数据库	❌	短周期内无法保证数据安全；服务器资源不足	换设备数据不迁移
纯浏览器存储	✅	数据不出浏览器，不存在"托管用户数据"的责任	受 localStorage 5MB 限制；清缓存即丢（已提供导出备份）

> 这不是"偷懒省事"，而是把风险明确地留在自己可控的范围内：宁可牺牲同步能力，也不做半吊子的数据托管。

2.2 不做向量检索

考虑过，评估后放弃。拦路的不是"难写"，而是四件工程代价：

成本项	具体问题
存储与计算	高维向量的存储和相似度计算开销高于当前规模所需
嵌入质量	检索效果几乎完全由嵌入模型决定，选型失败则整套方案失效
元数据过滤	需要按时间、来源、标签过滤，向量库的过滤能力参差
增量更新	新增/删除素材要维护索引一致性，还要处理多租户隔离

方案	选择	理由	代价
向量库 + 嵌入模型	❌	上述四项成本与当前素材规模不匹配	——
词面打分 + 云端模型判语义	✅	检索可离线、零成本、结果可解释；语义判断交给模型	同义改写可能召回不到

放弃向量检索之后，语义召回由云端模型承担。这个替代在当时看是划算的：

维度	向量检索	云端模型替代
实现成本	需索引、嵌入、增量更新	一次 API 调用
效果来源	嵌入模型质量决定上限	大模型本身的语言理解
运行成本	存储 + 计算常驻	按次计费，闲时为零
依赖	无网络要求	**必须有 Key、必须联网**

> 作者当时的判断原话：向量检索难度大，于是考虑用云端模型替代；替代之后，云端效果相比向量检索还有一些优势。

代价在 2.5 里交代：一旦没有 Key 或断网，语义能力就退回词面匹配。

这个决定直接引出了 2.4：既然不靠向量做语义召回，模型的判断就不能被"检索不到"卡死，于是允许它在标注清楚的前提下补充库外知识。

2.3 冲突必须由用户判断

模型只输出「这两条矛盾，争的是 X」，**不给结论。**用户必须选一边或选「都保留」，并写一句判断。

> 理由（作者原话）：学习效果来自持续的反馈，而不仅仅是内容堆砌。让用户自己处理冲突，一是让他知道自己的知识库里存在矛盾观点，二是让他自行决定取舍——这比模型自动处理更贴近他真实的想法。

换句话说：模型替用户决定，产品就退化成"总结器"，用户失去判断力的训练。

代价：多一步操作，流程更重。这是**刻意的摩擦。**

2.4 允许库外知识，但必须分区

初版只能答库内内容，导致「库里有相关内容但检索不到」时直接失效。现改为两段式：

```
【库中依据】  只用素材，每句带 [1][2]
【库外补充】  模型自身知识，前端用琥珀色块单独呈现
```

> 理由：拒绝回答会毁掉可用性；混在一起会毁掉可信度。分区是唯一同时保住两者的做法。

2.5 云端全部可降级

没有 Key、断网时，检索、缺口、简报、图谱（本地算法）全部可用。

> 理由：很多 AI 作品断网即白屏。可降级意味着产品的核心价值不完全依赖外部服务。

---

3. 系统架构

3.1 技术栈

层	选型
框架	Next.js 15.5（App Router）+ React 19
语言	TypeScript（strict）
样式	Tailwind v4（CSS-first）+ 设计令牌
状态	Zustand（含 localStorage 持久化）
3D	three.js 0.186
PDF	pdfjs-dist（浏览器端）+ unpdf（服务端兜底）
部署	阿里云轻量服务器 · pm2 · Node 22

3.2 结构

```
app/
  page.tsx                落地页（Server Component）
  kb/page.tsx             知识库工作台
  kb/settings/page.tsx    模型接入
  api/                    9 个接口
components/kb/            8 个视图 + 弹窗 + 抽屉 + 图谱
lib/kb/                   领域逻辑（检索、图谱、冲突、生成、备份）
lib/server/               服务端：模型解析、SSRF 防护、错误翻译
```

3.3 数据流

```
用户操作
   ↓
Zustand store ──localStorage──→ 素材 / 冲突 / 关系 / 配置
   ↓ 需要云端时
fetch /api/*  ──→ 服务端校验（SSRF / 限流 / token 预算）
                    ↓
                转发给 OpenAI 兼容端点（用户 Key 优先，其次服务端 Key）
                    ↓
                结果回到 store，落 localStorage
```

关键点：**服务端不存任何用户数据**，只做转发与防护。



图 1　系统架构：浏览器持有数据，服务端只做转发与防护

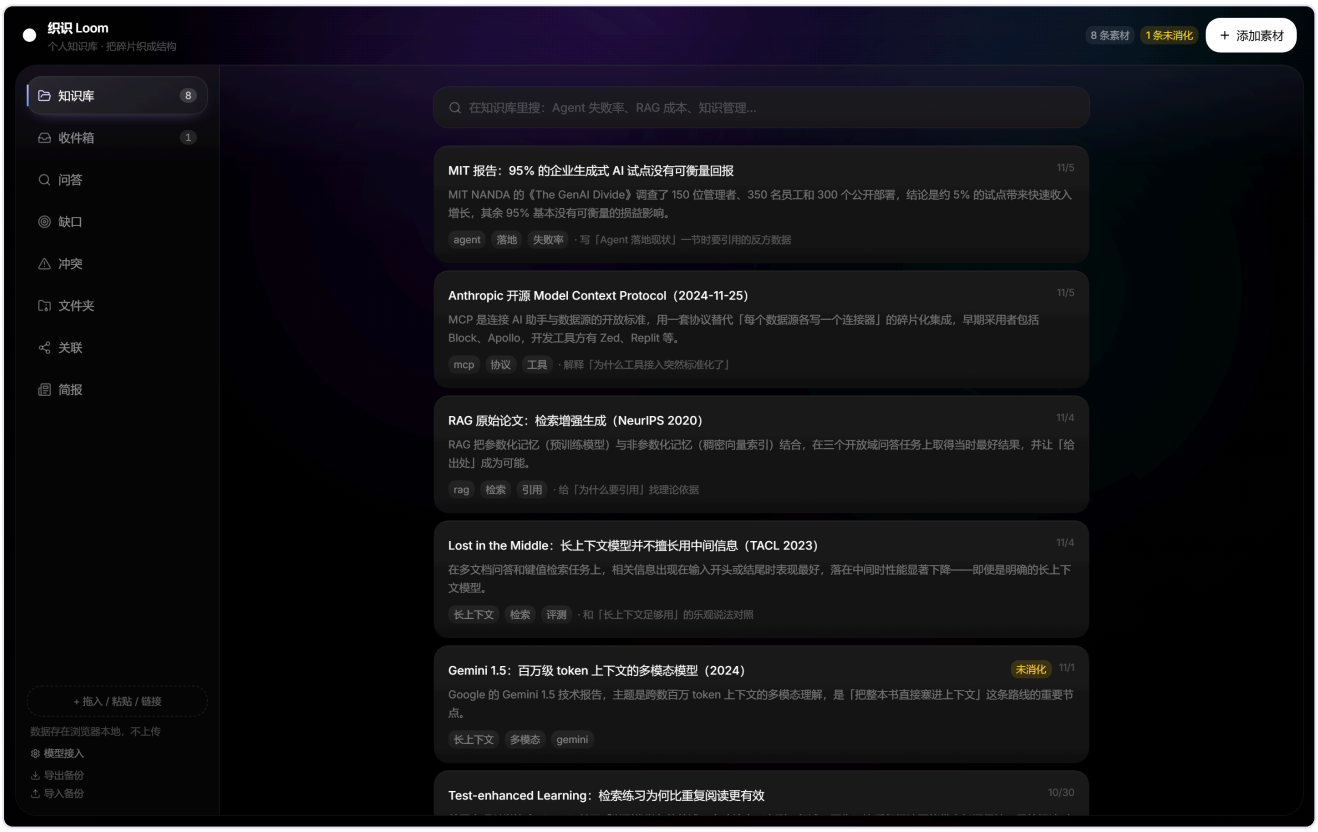


图 2　知识库主视图：搜索、清单、标签与「为什么存它」

3.4 九个接口

接口	作用	防护
`/api/relations`	判定素材间关系	限流 + token 记账 + JSON 容错
`/api/generate`	简报 / 问答 / 意图 / 冲突分析	同左
`/api/vision`	图片转文字	图片头校验 + 体积上限
`/api/vision/test`	视觉能力测试（真发图）	30s 超时
`/api/pdf`	PDF 解析（服务端兜底）	体积/页数上限 + 抓取限额
`/api/ingest`	网页正文抓取	**SSRF 防护** + 逐跳重定向校验 + 2MB 上限
`/api/llm/test`	连接测试 + 列出可用模型	15s 超时
`/api/health`	部署体检 + 额度查询	不返回任何密钥内容
`/api/metrics`	运行时指标（延迟、成功率、错误分布）	只读聚合，不含任何用户内容

---

4. 关键实现

4.1 本地检索与引用

`lib/kb/answer.ts`：分词 → 覆盖度打分 → 取前 N 条 → 拼原文片段。

- 相关性阈值：`hits >= 2 && score >= top * 0.45`，避免微弱命中污染结果
- 已确认分歧的素材对被同时拉入，保证冲突不被"检索漏掉"
- 引用编号与展示编号严格对齐（模型标注的 `[1]` 不会指错）

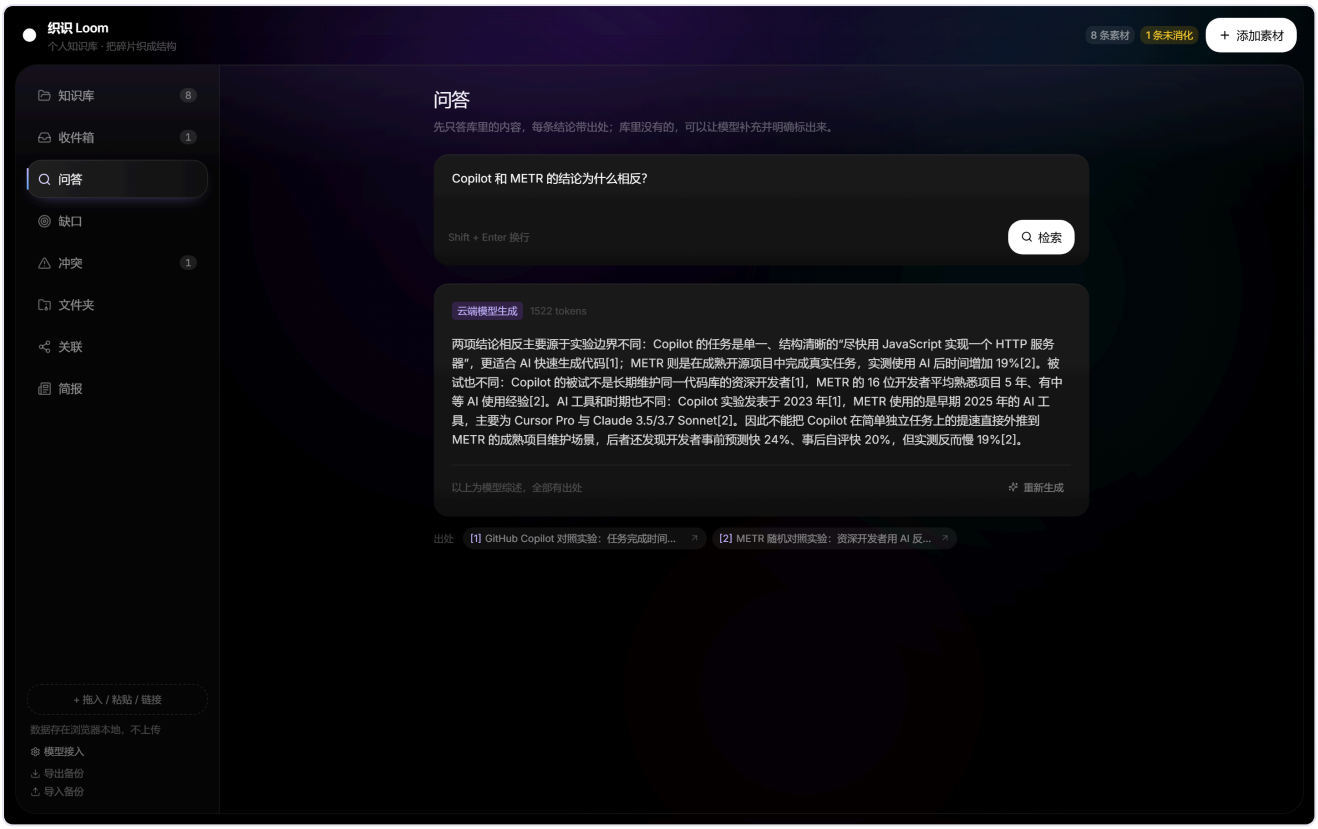


图 3　问答的两段式输出：上半部分每个结论带 [1][2] 出处，下半部分是独立的「库外补充」

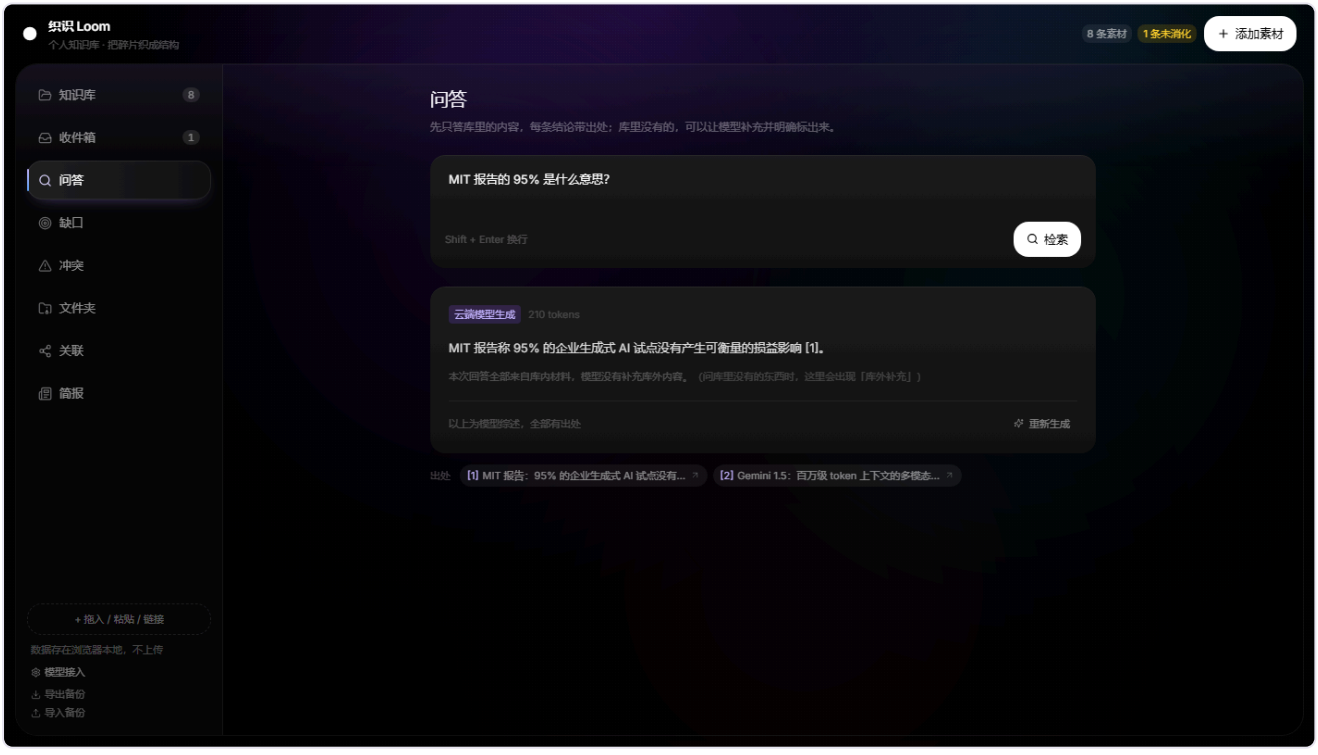


图 3b　材料足够时，界面明确说明「没有补充库外内容」，避免被误认为功能缺失

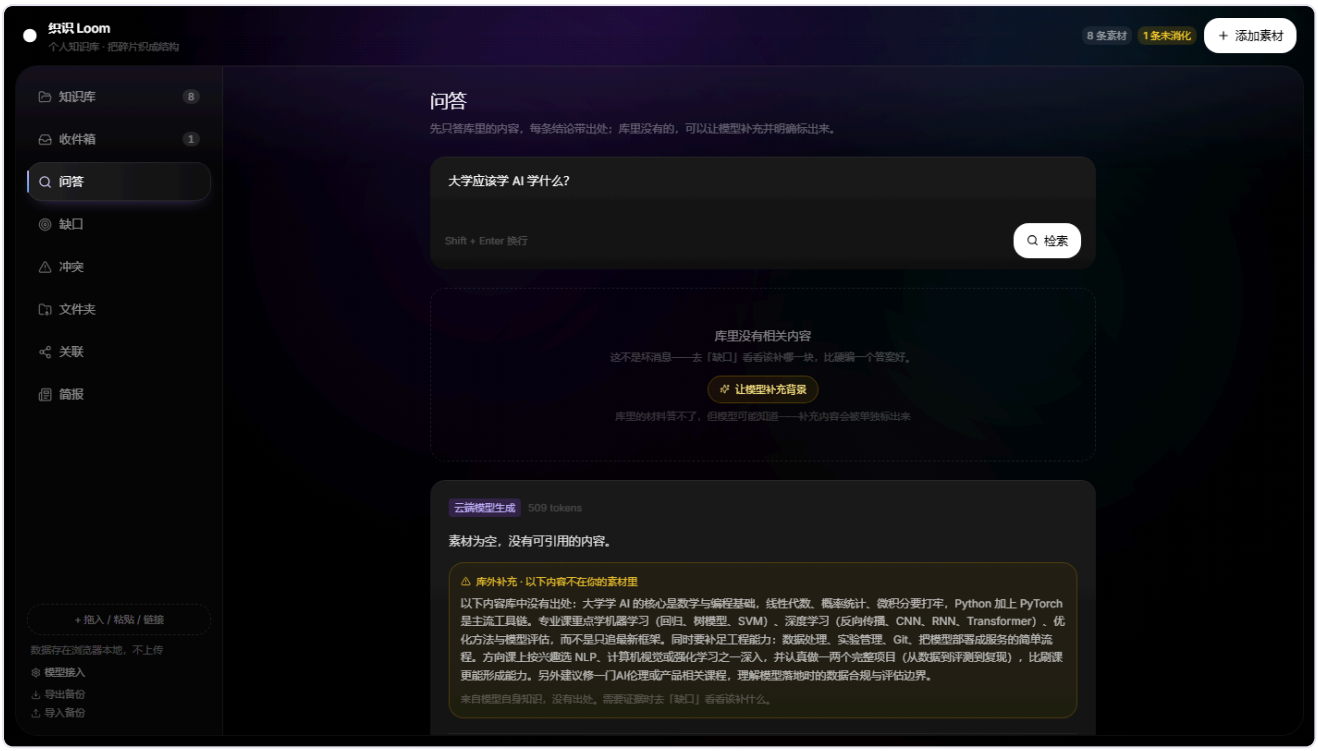


图 3c　库里完全没有相关内容时：仍可让模型补充背景，结果全部标为「库外补充」

4.2 关系判定的容错

模型输出不可控，做了四层容错：

1. **去代码围栏** + 按括号深度截取最外层 JSON
2. **字段别名**：`a|source|from`、`b|target|to`
3. **kind 归一**：`contradiction/conflict → contradicts`
4. **失败重试一次**，追加更严格的指令

> 若不处理，模型返回 `source/target` 时会被静默丢弃，接口返回 200 但关系为 0——用户以为"模型觉得没关系"。

4.3 冲突的派生与可逆

冲突不是预置数据，而是从 `kind === "contradicts"` 的关系**派生**出来的。

- 判断必须填写 note 才能关闭
- `resolveConflict` 完全可逆：改判时先清除双方的 `supersededBy / absorbedBy / disputesWith`，再应用新选择
- 被吸收的素材进「文件夹」，详情页可交叉跳转到对方



图 4　冲突处理链路：模型只指出矛盾，判断由用户完成

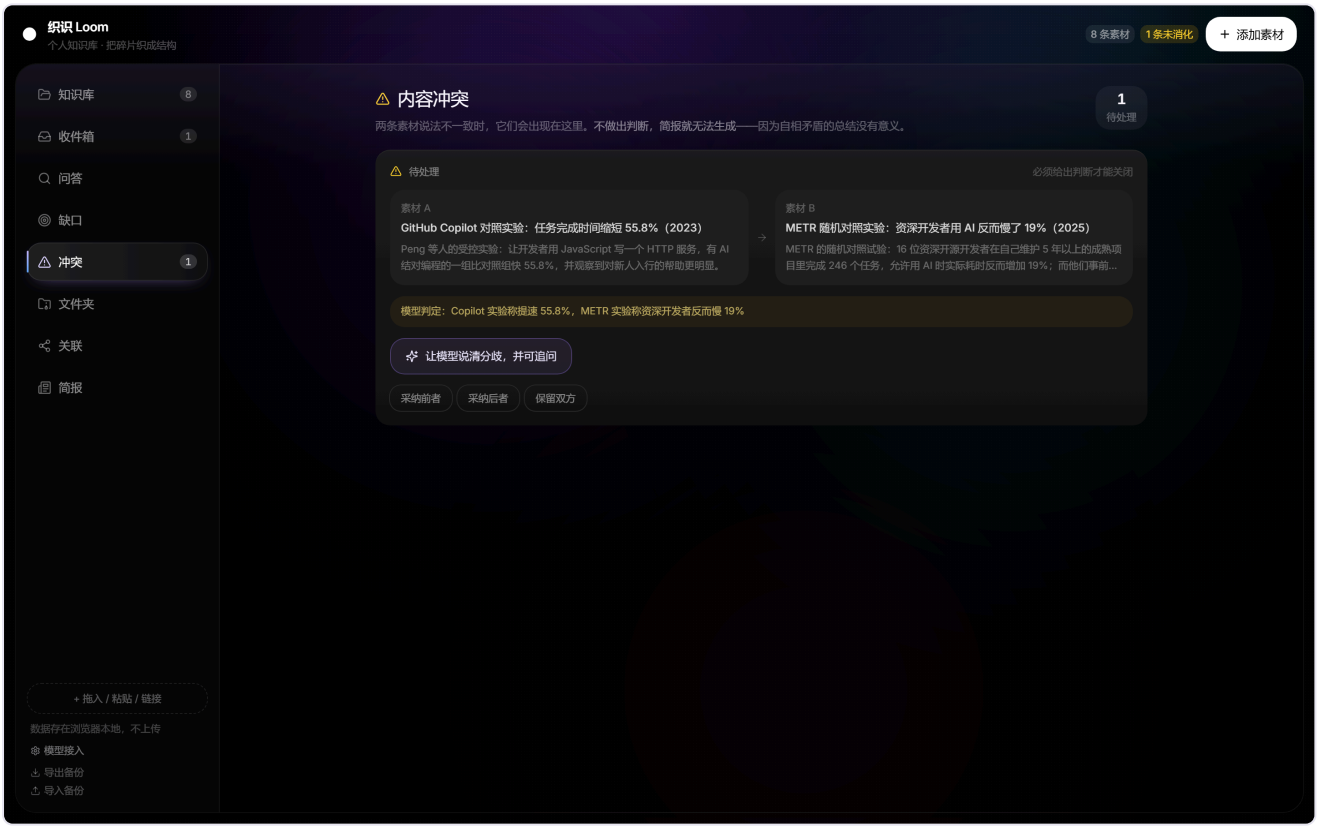


图 5　冲突页：必须给出判断才能收口，可选「让模型说清分歧，并可追问」

4.4 3D 图谱的性能

手段	效果
DPR 上限 1.25	2 倍屏像素少 44%
30fps 上限 + 离屏暂停	静止时几乎零开销
泛光默认关闭，测 8 帧渲染耗时 < 7ms 才开	弱卡不拖垮
粒子 900→520，耀斑 110→70	绘制调用减少
渲染耗时 > 16ms 自动降级（关泛光 + DPR 0.85）	兜底

> 关键教训：用 **rAF 间隔**判断"慢"是错的——限帧 30 后间隔恒为 33ms，会误判。必须测渲染耗时。

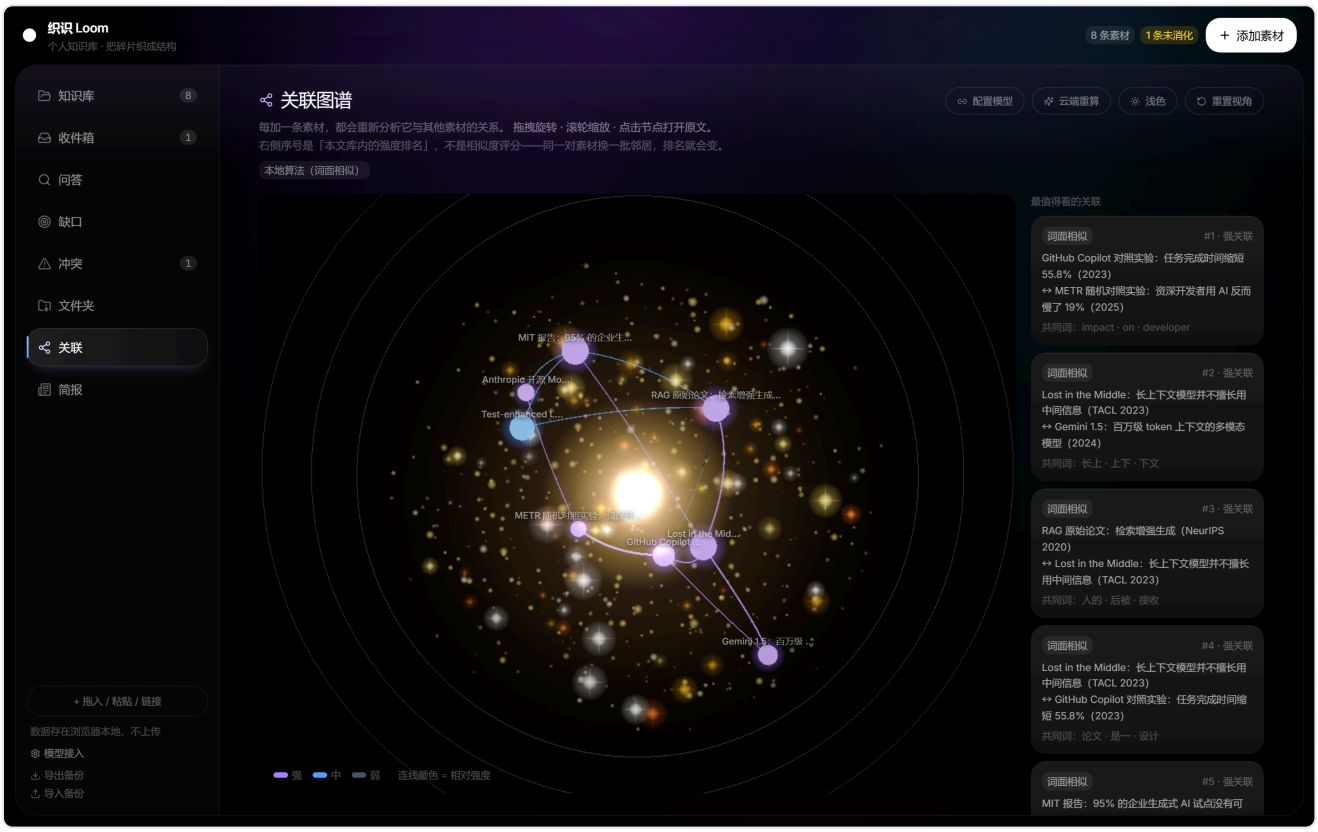


图 6　关联图谱：节点大小表示关联度，右侧列出最值得看的关联

4.5 PDF：浏览器内解析

`pdfjs-dist` 在前端解析，文件不上传，因此**没有 4MB 限制。**

- worker 由 `postinstall` + `prebuild` 复制到 `public/`
- 300 页 / 7.2MB 的 PDF 实测解析出 127 万字，全程零网络请求
- 超过 4 万字自动截断（localStorage 容量所限），并在界面上明确提示
- 扫描件无文字层时提示改用图片入口

4.6 图片：阶梯压缩

```
[1280, 0.80] → [1100, 0.75] → [960, 0.70] → [800, 0.65] → [640, 0.60]
目标：base64 ≤ 1.2M，达标即停
```

实测 6.6MB / 3600×2400 的 PNG，压缩后发给模型的 JSON 仅 112KB。

视觉能力来自主模型本身：DeepSeek-V4.1-Flash 的输入模态包含图片，所以**不必额外配置视觉模型**；只有换成纯文本模型时，才需要在设置页单独填一个（如 `glm-4v-flash`）。

4.8 从「缺口」到「补上」

问答里出现「库外补充」时，就意味着这块证据库里没有。光指出缺口还不够，得能补。

于是在结果下方给出下一步：**让模型推荐几篇能补上的真实材料，用户决定加不加。**

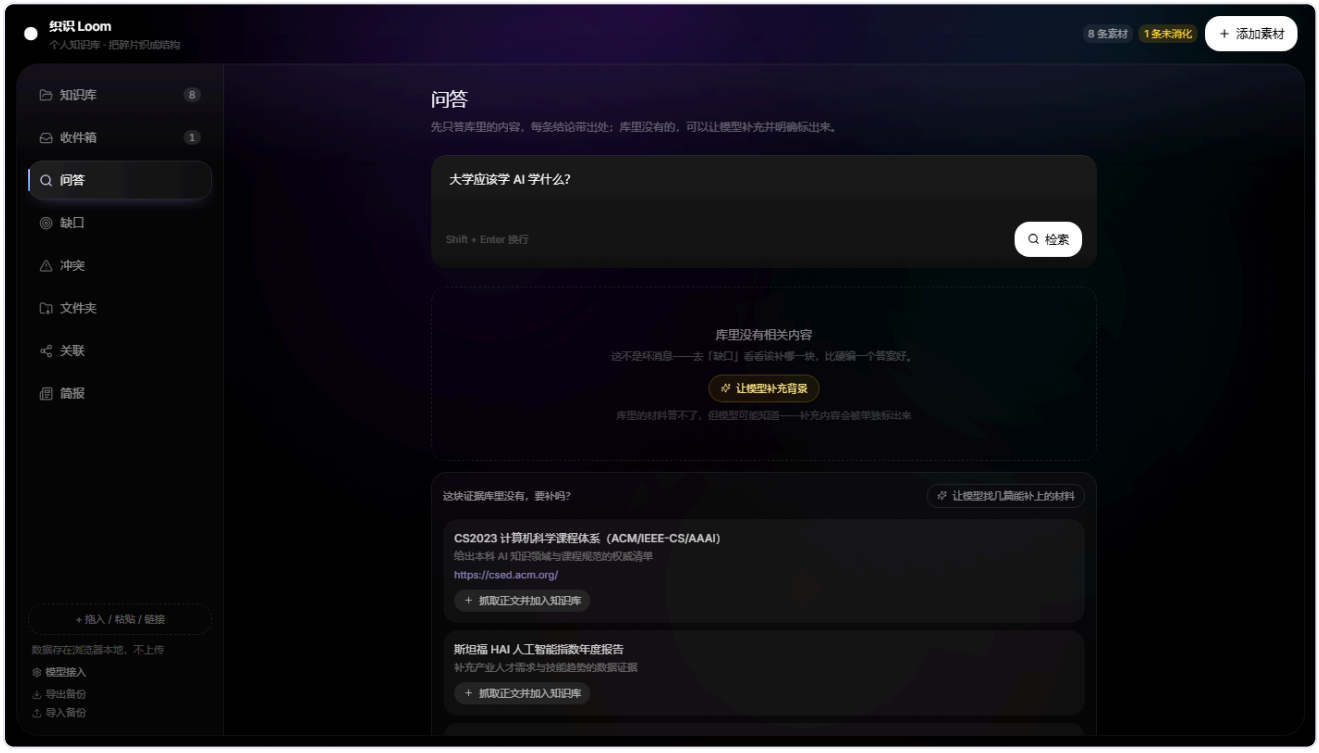


图 6b　库内无据时给出补充入口，可让模型推荐真实材料

设计上有三条约束：

约束	做法	原因
不许编造链接	提示词要求「不确定就留空 url」	假链接比没建议更糟
用户决定	每条都有独立的「抓取正文并加入知识库」	推荐不等于入库
抓不到就说	抓取失败直接报错，不假装成功	假成功会污染知识库

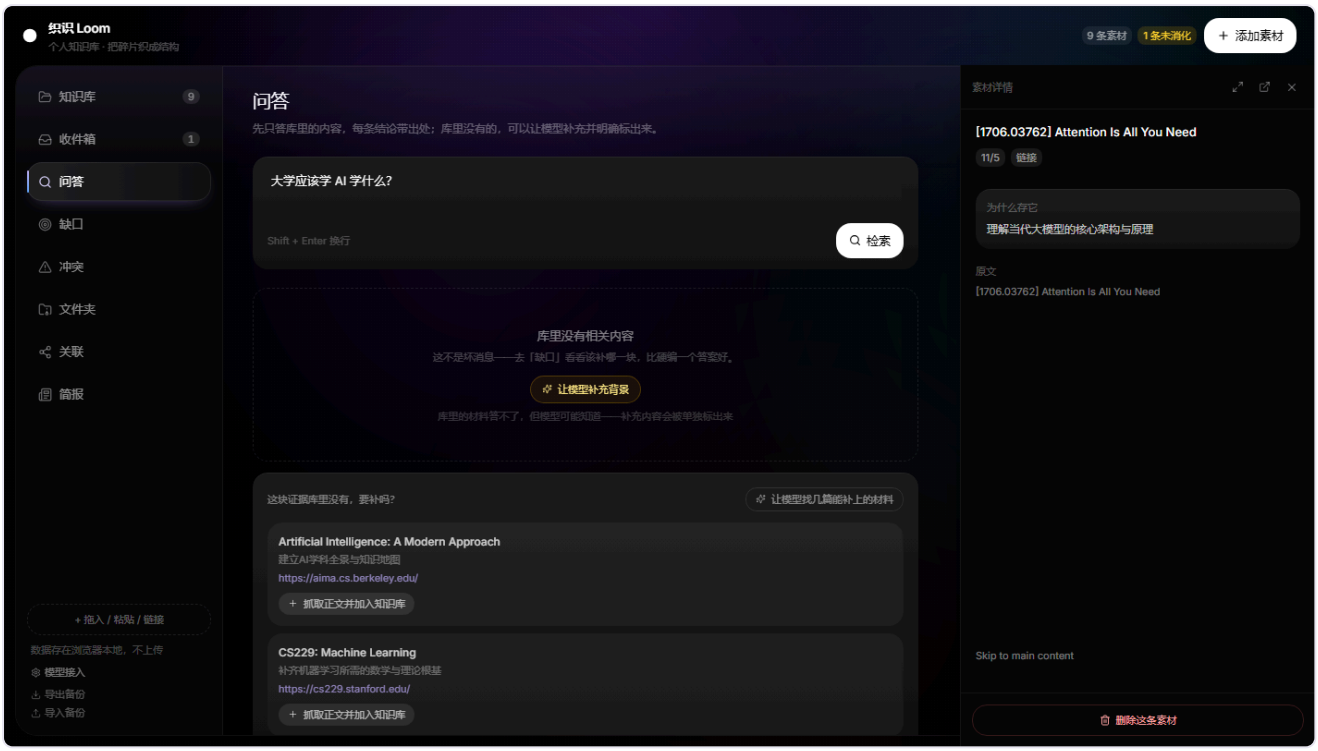


图 6c　抓取成功后素材进入知识库，带着「为什么存它」的理由

入库时会自动写入一条收藏理由（如「为回答「大学应该学 AI 学什么？」补充的证据」），这样新增的素材仍然符合产品规则：**存进来就要有理由。**

实测：问「大学应该学 AI 学什么」，模型给出 CS2023、AIMA、CS229 等真实材料；点其中一条的 arXiv 链接，成功抓到《Attention Is All You Need》并入库，素材数 8 → 9。

4.7 安全

风险	处理
SSRF（`/api/ingest` 抓任意 URL）	私网/回环/元数据地址拦截；DNS 解析后再校验；重定向逐跳校验；响应体 2MB 上限
配额耗尽导致账单失控	每 IP 20 次/天 + 全站 300 次/天 + **token 预算 90 万/天**
配额计数跨路由失效	计数挂 `globalThis`（Next 各路由是独立模块）
Key 泄露	只存浏览器或服务端环境变量；不落库、不打日志、不进仓库

4.9 可观测性与错误可诊断

产品是本地优先的：数据不出浏览器，也没有账号。所以「可观测性」只该回答一个问题—— **线上出问题时，能不能判断坏在哪一层。**

记录什么，不记录什么

记录	不记录
路由名、状态码、耗时	用户的问题内容
token 消耗、是否共享 Key	素材标题或正文
错误分类（auth / quota / upstream / invalid）	API Key
聚合后的 P50 / P95	IP 地址

这条边界是刻意的：一旦日志里出现用户的问题，产品最核心的隐私主张就不成立了。

实现

- 计数挂在 `globalThis`：Next 每个路由是独立模块，模块级变量不共享（做 token 预算时踩过这个坑）
- 用一个 `withMetrics(route, handler)` 包装器，套在 5 个业务路由上
- 每个路由保留最近 200 次耗时样本，用来算分位

`GET /api/metrics` 的返回（实测）：

```
{
  "uptimeMinutes": 1,
  "requests": { "total": 2, "ok": 1, "fail": 1, "successRate": 0.5 },
  "routes": [
    { "route": "generate", "count": 2, "ok": 1, "fail": 1, "p50": 104, "p95": 4086 },
    { "route": "relations", "count": 1, "ok": 1, "fail": 0, "p50": 1292, "p95": 1292 }
  ],
  "errors": { "upstream": 1 },
  "tokensUsed": 715,
  "note": "只含运行时聚合数据：不含问题、素材、Key 与 IP"
}
```

设置 `METRICS_TOKEN` 后需要口令才能读；不设置则返回聚合数字。两种模式都不含用户内容。

除了 JSON，还有一个可视化页面 `/kb/metrics`（从「模型接入」页进入）：

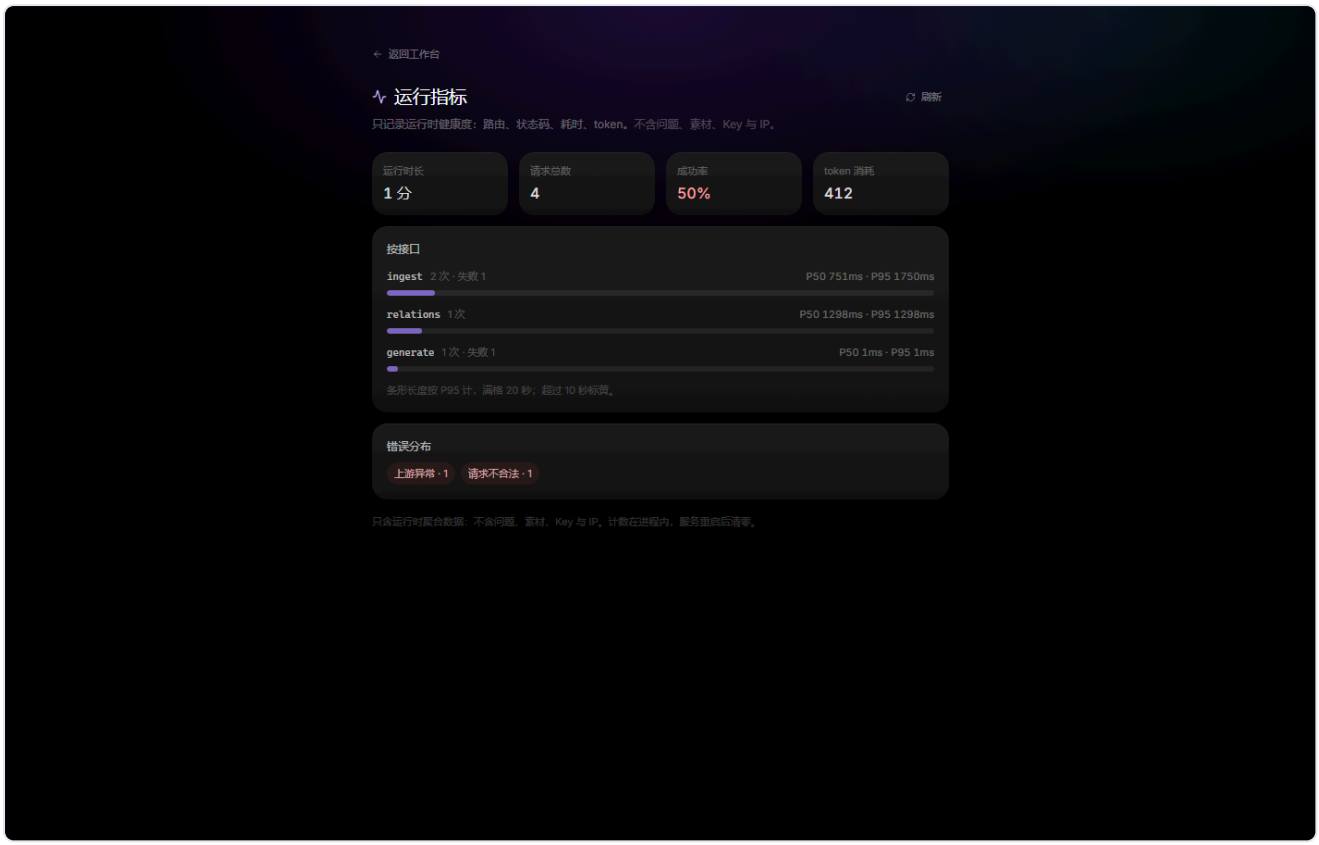


图 8c　运行指标页：成功率、各接口 P50/P95、错误分布

页面把三件事放在一屏里：

区块	回答的问题
四个数字	服务还活着吗？成功率有没有掉？
按接口的 P50/P95	慢在哪个接口？（`relations` 12 秒，`ingest` 不到 1 秒）
错误分布	坏在哪一层？鉴权、额度、上游，还是请求本身不合法

条形长度按 P95 计，满格 20 秒，超过 10 秒标黄——一眼能看出哪个接口有性能风险。

错误可诊断，而不是「请联系管理员」

最初的建议是「报错就弹联系管理员」。这里没有采纳，原因不是不想做容错，而是 **这个产品没有管理员**——数据在用户浏览器里，没有账号体系，也没有人会接那个电话。 一个承诺了却接不住任何人的入口，比没有更糟。

替代做法是让错误**可复制、可定位**：错误条右侧有「复制」，点一下得到

```
时间    2026/11/6 01:12:44
页面    /kb
接口    POST /api/generate
状态    502
错误    上游服务暂时不可用
浏览器  Mozilla/5.0 (Windows NT 10.0; Win64; x64) … Chrome/142
```

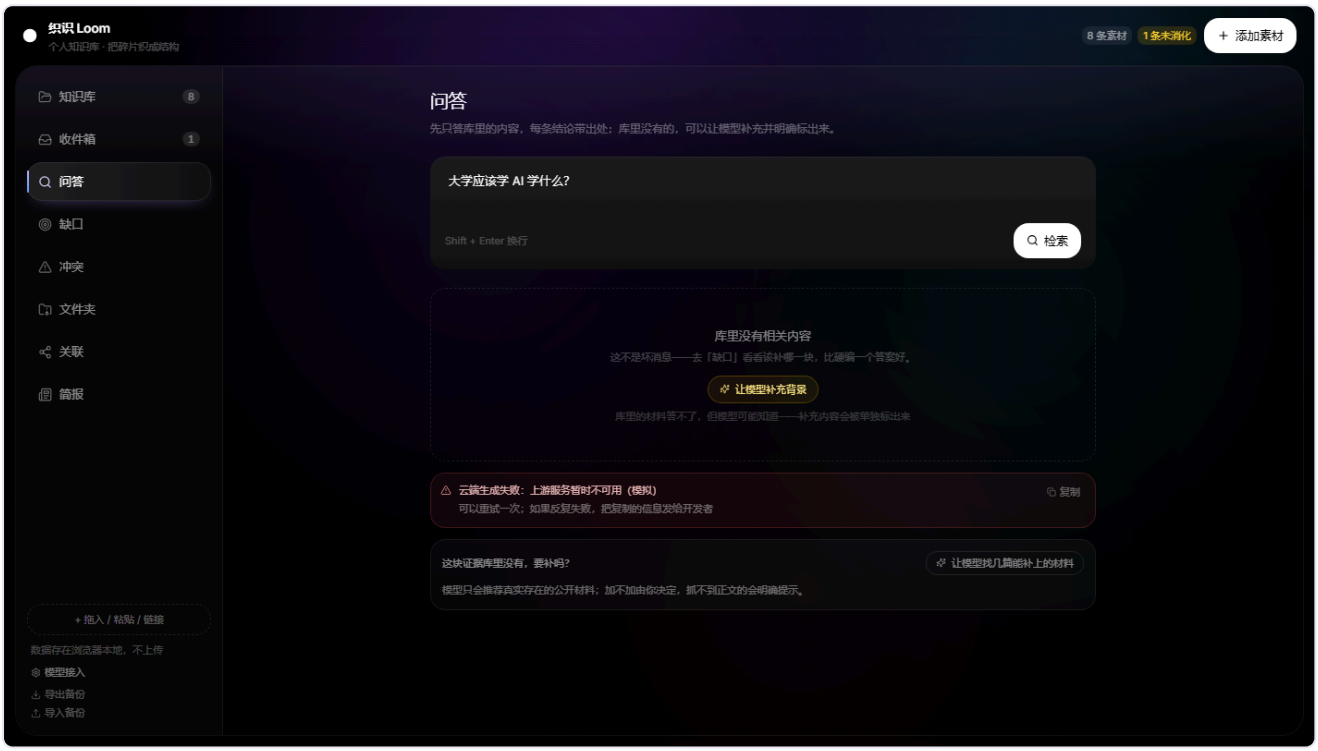


图 8b　错误提示：一句话说清 + 一句「能做什么」+ 可复制的诊断信息

这比「请联系管理员」更符合产品形态：**单人使用，也能自己排查，或者把这段发给开发者。**

5. 评测

> 所有数字均为线上环境（http://8.163.104.134）实测，DeepSeek-V4.1-Flash，2025-11。

5.1 功能验证

项	方法	结果
设计规则	`pnpm audit:ui`（8 条）	8/8
单元测试	`node --test`	6/6
端到端	`pnpm test:e2e`（真实 Chrome）	4/4
视觉识别	296KB 界面截图	完整读出结构与文字
PDF 解析	7.2MB / 300 页	127 万字，零上传

5.2 关系判定质量

方法：人工设计 20 条素材并标注真值，其中

- 2 对已知矛盾（Copilot 55.8% vs METR −19%；长上下文够用论 vs Lost in the Middle）
- 1 对重复（同一份 MIT 报告的两种表述）
- 2 对支持关系
- 7 条互不相关的学习方法素材（用于测误连）

每轮把 20 条一次性交给模型，连续跑 4 轮。

指标	结果	说明
矛盾召回	**2 / 2**	4 轮全部命中，无遗漏
重复召回	**1 / 1**	同上
矛盾误报	0.3 条/轮	偶发把「RAG 优于纯参数模型」与「全文入上下文替代 RAG」判为矛盾，可辩护
无关素材误连	4.0 条/轮	7 条学习方法之间被判为 related，语义上可辩护但偏松
平均关系数	13.0 条	20 条素材，约 1.3 条/素材
平均耗时	**12.3 秒**	含网络与推理
平均 token	**3,302**	单次重算成本约 ¥0.004

过程中发现并修复的问题：初版 `max_tokens = 2200`，20 条素材时有 1/3 的请求被截断，返回「输出被长度限制截断」。提高到 4096 后 4/4 成功。



图 7　关系判定评测结果：矛盾与重复 100% 检出，噪声来自泛相关

结论：模型在**该找的矛盾上没漏**（召回 100%），代价是**关联判得偏松**——把同属"主动学习"的七条方法互相连了起来。对产品的含义是：高价值信号（矛盾）可靠，低价值信号（泛相关）需要用户自己筛。

5.3 问答质量

方法：4 个问题覆盖三类场景，逐条人工判定。判据：是否带引用编号、是否区分"库中依据/库外补充"、是否编造。

用例	场景	引用	两段结构	人工判定
A	库内可答（矛盾对比）	✅ [1][2]	✅	**通过**：分别陈述两实验，并指出条件不同
B	库内可答（单材料）	✅ [1]	✅	**通过**：未编造论文外数据
C	**库内不可答**（注意力复杂度）	✅	✅	**通过**：明确说「素材中没有相关内容」，复杂度只出现在库外补充
D	跨材料综合（能否替代 RAG）	✅ [1][2][3]	✅	**通过**：分述两种立场与成本，未合并成单一结论
E	库内完全无结果（大学学 AI 学什么）	无（无素材）	✅	**通过**：明确说「素材为空」，全部内容进入库外补充

指标	结果
引用标注率	4 / 4
两段结构合规率	4 / 4
编造数据	0 例
平均耗时	**3.3 秒**（2.6–4.4s）
平均 token	**668**（527–913）

C 用例最能说明设计意图：模型没有硬凑答案，而是先说"这两条素材都是 AI 编程工具实验，无法回答"，再把复杂度知识放进库外补充。

5.4 性能

测试条件：Chrome 移动端 390×844，**4G 网络（9Mbps / RTT 85ms）+ 4 倍 CPU 降速。**

页面	LCP	DOMContentLoaded	load
落地页 `/`	**2,628ms**	2,873ms	2,874ms
工作台 `/kb`	**1,276ms**	332ms	334ms

其他指标：

项	结果
图谱帧率	桌面端稳定在 30fps 上限内（主动限帧）
移动端横向溢出	0px（8 个视图全部通过）
云端重算（8 条素材）	12–20 秒
图片压缩	6.6MB PNG → 112KB 请求体

> 落地页 LCP 偏高，主要来自 3D 星云首次编译着色器；已做 DPR 上限、30fps 限帧与离屏暂停，但在 4 倍 CPU 降速下仍有 2.6 秒。工作台页面因为没有 3D 首屏，LCP 仅 1.3 秒。

5.5 评测本身的局限

这些数字能说明"能用"，但**不足以说明"可靠"**，原因有三：

1. **规模小**：20 条素材，无法代表上百条的真实知识库（关系数随规模超线性增长）
2. **真值单人标注**：是否算"矛盾"本身有判断空间，换个人标可能得到不同数字
3. **只测了一个模型**：DeepSeek-V4.1-Flash，换模型结论可能完全不同

如果要让它更像实验，至少还要补：多名标注者、更大的素材集、跨模型对比。

6. 局限与后续

6.1 已知局限

1. **数据只在单台浏览器**：换设备不迁移，清缓存即丢（可导出 JSON 备份）
2. **localStorage 约 5MB**：单条正文入库上限 4 万字
3. **无账号体系**：无法分享、协作
4. **冲突判定依赖模型**：模型判错时用户只能改判，不能校正模型
5. **无 HTTPS**：当前 HTTP 访问，演示够用
6. **评测规模有限**：20 条素材、单人标注真值、仅测一个模型（详见 5.5）

6.2 如果再多两周

会先补账号体系——但这**不推翻 2.1 的决定**，而是承认那是"时间与资源受限下的取舍"：

约束	当时的情况	有两周的情况
时间	安全做不完	够做实名 + 会话 + 加密存储
服务器	2 核 2G，无余力建库	可加一台数据库实例
结论	宁可不做，也不做半吊子	可以做完整版本

顺序会是：**账号 → 加密存储 → 端到端同步 → 冲突合并策略。**最后一步最难，因为要处理"两台设备同时改同一条素材"。

6.3 最不放心的地方：会不会没人用

技术上最不放心的是数据只在本地；但**真正的不安全感来自需求本身**——这个产品解决的是「收藏了不看」，而这件事的痛点强度，只有真实用户能验证。

目前支撑它的证据只有三条：

1. 作者自己的短视频收藏夹（第 1 节）
2. 身边同学的类似反馈
3. 20 条素材上的功能验证

这三条都不足以证明"有人愿意为此改变行为"。**一个逼用户输出的工具，最大的风险是用户嫌麻烦。**

这也是下一步最该做的事：**找 5 个真实用户用两周，看他们第 8 天还会不会打开。**如果不会，功能做得再多也没有意义。

6.4 从"作品"到"产品"还差什么

- 账号与数据同步（能力问题）
- 真实用户的使用数据（验证问题，比能力更关键）

- 关系判定的持续评测与提示词迭代（质量问题）

---

7. 附录

7.1 复现

```
pnpm install
pnpm dev            # 开发
pnpm demo           # 构建 + 启动
pnpm verify         # 设计规则 + 类型 + 单测
pnpm test:e2e       # 浏览器冒烟（需先启动服务）
```

7.2 部署

见 `docs/DEPLOY.md`（Vercel）与 `deploy/README.md`（自建服务器）、`deploy/aliyun.md`（阿里云）。

7.3 数据来源

内置 8 条素材均为**真实公开材料**，标题、日期、链接可核对。其中两条（GitHub Copilot 对照实验 / METR 随机对照实验）是**刻意选的矛盾证据**，用于演示冲突检测。

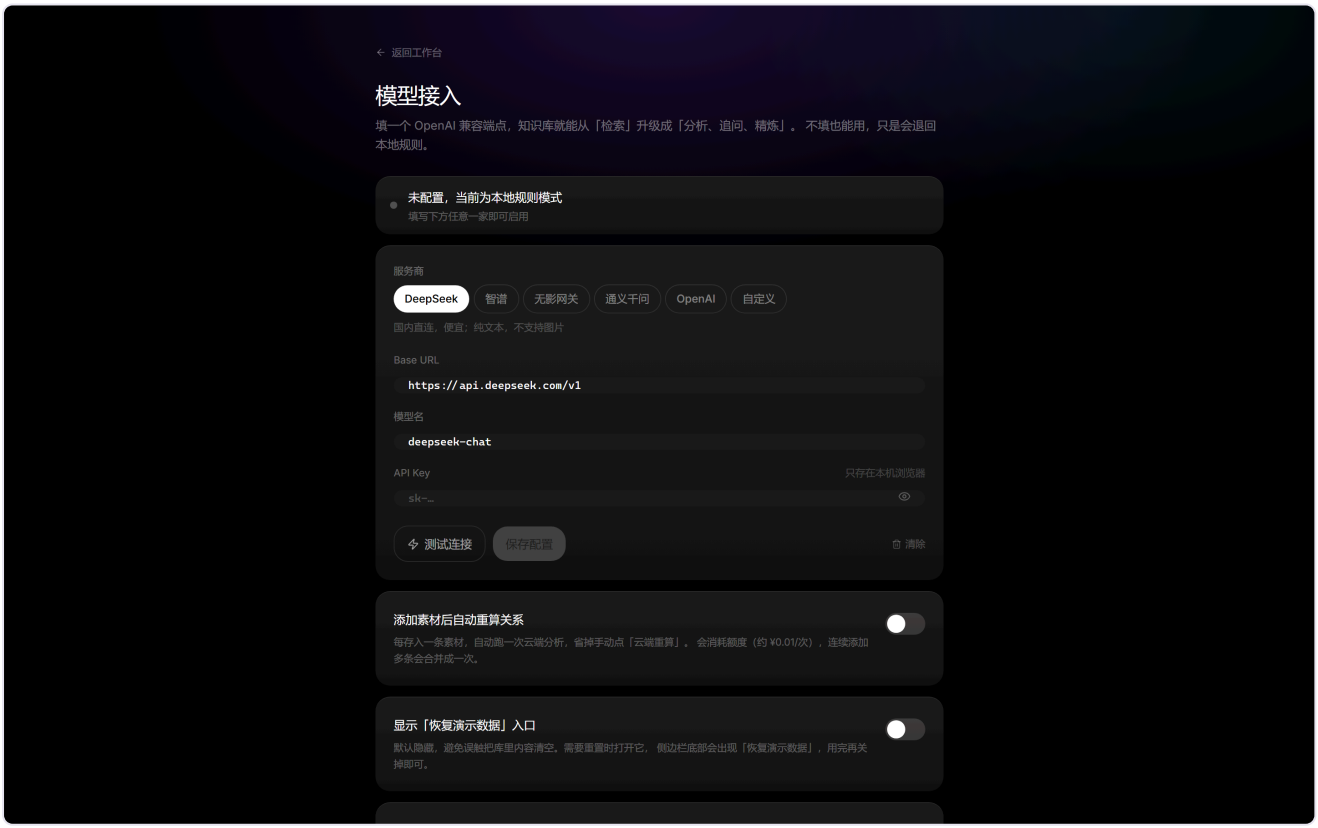


图 8　模型接入页：主模型支持图片时，视觉三栏留空即可复用

7.4 第三方依赖

依赖	用途	许可
next / react	框架	MIT
three	3D 图谱	MIT
pdfjs-dist	PDF 解析	Apache-2.0
unpdf	服务端 PDF 兜底	MIT
lucide-react	图标	ISC
zustand	状态	MIT